

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA TRÍ TUỆ NHÂN TẠO

SEMI-SUPERVISED LEARNING

Hà Nội, 26-08-2026

TÓM TẮT

Báo cáo này trình bày tổng quan về Học bán giám sát (Semi-supervised Learning - SSL), một phương pháp tiếp cận trong lĩnh vực học máy nhằm giải quyết thách thức khi dữ liệu có nhãn khan hiếm và tốn kém để thu thập, trong khi lượng dữ liệu chưa dán nhãn lại vô cùng dồi dào. Nội dung báo cáo đi từ việc làm rõ các khái niệm nền tảng, so sánh khả năng khái quát hóa của SSL so với các phương pháp học có giám sát và học không giám sát truyền thống. Báo cáo cũng phân tích chi tiết cơ chế hoạt động của SSL thông qua các giả định nền tảng (giả định cụm, độ mịn, mật độ thấp, đa tạp) và các thuật toán đặc trưng như lan truyền nhãn (label propagation) hay phương pháp học quy nạp (tự đào tạo, đồng đào tạo).

Tiếp nối nền tảng lý thuyết, tài liệu đi sâu vào phân tích Hệ thống đề xuất (Recommendation Engine) – một trong những ứng dụng thực tiễn nổi bật nhất giúp định hình trải nghiệm người dùng. Trọng tâm của phần này là việc đối chiếu hai kiến trúc cốt lõi: Lọc cộng tác (Collaborative filtering) và Lọc dựa trên nội dung (Content-based filtering). Thông qua việc phân tích các cấu trúc dữ liệu biểu diễn (ma trận người dùng - vật phẩm, không gian vectơ đặc trưng) và các thước đo toán học (độ tương đồng Cosine, hệ số tương quan Pearson, khoảng cách Euclid), báo cáo làm rõ nguyên lý phân loại và dự đoán của từng phương pháp. Đồng thời, tài liệu cũng đánh giá khách quan những ưu điểm và các thách thức lớn như vấn đề khởi động lạnh (cold-start problem) hay dữ liệu thưa thớt (data sparsity). Tổng thể, báo cáo cung cấp một góc nhìn toàn diện và logic từ lý thuyết cơ sở của học máy đến khả năng ứng dụng thực tế

HỌC BÁN GIÁM SÁT LÀ GÌ?

Khái niệm về Học bán giám sát

Học bán giám sát là một nhánh của học máy kết hợp học có giám sát và không giám sát bằng cách sử dụng cả dữ liệu được dán nhãn và không được gán nhãn để huấn luyện các mô hình trí tuệ nhân tạo (AI) cho các nhiệm vụ phân loại và hồi quy.

Mặc dù học bán giám sát thường được sử dụng cho các trường hợp sử dụng giống nhau trong đó người ta có thể sử dụng các phương pháp học có giám sát, nhưng nó được phân biệt bằng nhiều kỹ thuật khác nhau kết hợp dữ liệu chưa được gán nhãn vào đào tạo mô hình, bên cạnh dữ liệu được dán nhãn cần thiết cho việc học có giám sát thông thường.

Các phương pháp học bán giám sát đặc biệt phù hợp trong các tình huống khi việc thu thập đủ lượng dữ liệu được dán nhãn là cực kỳ khó khăn hoặc tốn kém, nhưng lượng lớn dữ liệu không được gán nhãn lại tương đối dễ dàng thu được. Trong những tình huống như vậy, cả phương pháp học tập được giám sát hoàn toàn và không giám sát đều không cung cấp được giải pháp đầy đủ.

Dữ liệu gán nhãn và học máy

Việc đào tạo AI cho các tác vụ dự đoán phụ thuộc rất nhiều vào phương pháp học có giám sát, nơi các mô hình sử dụng dữ liệu được dán nhãn làm "cơ sở thực tế" (ground truth) để giảm thiểu sai số trong quá trình huấn luyện. Tuy nhiên, việc chú thích dữ liệu thủ công tốn rất nhiều công sức, đặc biệt khi các tác vụ AI ngày càng phức tạp. Nếu phân loại hình ảnh cơ bản chỉ cần các thẻ danh mục đơn giản, thì các tác vụ nâng cao như phát hiện đối tượng hoặc phân đoạn hình ảnh lại đòi hỏi việc xác định ranh giới tỉ mỉ đến từng điểm ảnh (pixel).

Hơn nữa, trong các lĩnh vực chuyên sâu như khám phá thuốc, giải trình tự gen hoặc phân loại protein, việc chú thích dữ liệu không chỉ vô cùng tốn thời gian mà còn đòi hỏi kiến thức chuyên môn đặc thù khắt khe. Để vượt qua trở ngại của quá trình dán nhãn tỉ mỉ và đắt đỏ này, học bán giám sát (semi-supervised learning) mang đến một giải pháp hiệu quả. Phương pháp này khai thác tối đa giá trị của nguồn dữ liệu được con người dán nhãn khan hiếm bằng cách kết hợp liền mạch với lượng lớn dữ liệu chưa dán nhãn dồi dào, qua đó giảm thiểu đáng kể công sức thủ công mà không làm suy giảm năng lực của mô hình.


SO SÁNH CÁC PHƯƠNG THỨC HỌC MÁY

Học bán giám sát có thể được coi là sự kết hợp hoặc trung gian giữa học có giám sát và học không giám sát.

Semi-supervised learning vs supervised learning

Tiêu chí	Học có giám sát (Supervised learning)	Học bán giám sát (Semi-supervised learning)
Dữ liệu huấn luyện	Chỉ sử dụng các bộ dữ liệu đã được dán nhãn hoàn toàn.	Sử dụng kết hợp cả dữ liệu đã dán nhãn và chưa dán nhãn.
Cách thức hoạt động	Học ranh giới quyết định (decision boundary) để phân chia các danh mục chỉ dựa trên các điểm dữ liệu có nhãn.	Sửa đổi hoặc bổ sung một thuật toán có giám sát ("base learner") để tích hợp thông tin từ dữ liệu chưa dán nhãn. Dữ liệu có nhãn đóng vai trò định hướng và tạo cấu trúc cơ bản.
Khả năng khái quát hóa	Có thể khái quát hóa kém (đưa ra dự đoán không đáng tin cậy) đối với dữ liệu thực tế nếu chỉ được huấn luyện trên một số ít điểm dữ liệu có nhãn.	Khái quát hóa tốt hơn nhờ tận dụng được ngữ cảnh hữu ích từ các điểm dữ liệu chưa dán nhãn.
Khả năng xử lý dữ liệu chưa dán nhãn	Không thể xử lý hoặc tận dụng thông tin từ dữ liệu chưa dán nhãn.	Xử lý và khai thác hiệu quả bối cảnh từ lượng lớn dữ liệu chưa dán nhãn.
Rủi ro khi thiếu dữ liệu có nhãn	Rất dễ xảy ra hiện tượng quá khớp (overfit) vào số ít các điểm dữ liệu có nhãn (như ví dụ tập dữ liệu "half-moons").	Khắc phục được rủi ro quá khớp nhờ thông tin bổ sung từ dữ liệu chưa dán nhãn.

Bảng 1: So sánh giữa Học có giám sát và Học bán giám sát



Hình 1: So sánh ranh giới quyết định (decision boundary) trên tập dữ liệu half-moons

Tập dữ liệu half-moons

Cấu trúc dữ liệu: Đồ thị gồm một số lượng rất ít các điểm dữ liệu đã dán nhãn (hình lục giác màu xanh và tím) xen kẽ với lượng lớn các điểm dữ liệu chưa dán nhãn (hình tròn màu xám). Tổng thể các điểm này xếp thành hình hai nửa vầng trăng lồng vào nhau.

Ranh giới quyết định sai lệch: Thuật toán học có giám sát truyền thống không thể xử lý dữ liệu chưa dán nhãn, nó hoàn toàn phớt lờ các điểm màu xám mang tính ngữ cảnh. Mô hình chỉ học từ số ít điểm xanh/tím và vạch ra một ranh giới phân loại là một đường thẳng màu đen nằm ngang.

Overfitting: Đường thẳng đen này tuy phân tách thành công các điểm màu xanh và màu tím ít ỏi hiện có, nhưng lại cắt ngang qua cấu trúc vầng trăng tự nhiên của bộ dữ liệu. Nó cho thấy mô hình đã học một cách máy móc và khái quát hóa rất kém đối với dữ liệu thực tế, dẫn đến việc sẽ phân loại sai (misclassifying) rất nhiều điểm dữ liệu mới trong tương lai.

Thông điệp của biểu đồ là: Dữ liệu chưa dán nhãn (màu xám) cung cấp bối cảnh cấu trúc rất hữu ích mà mô hình có giám sát bị bỏ lỡ. Nếu sử dụng học bán giám sát (semi-supervised learning), mô hình sẽ tận dụng được các điểm màu xám để nhận ra cấu trúc "vầng trăng" và vẽ ra một đường cong ranh giới phân chia chính xác hơn.

Semi-supervised learning vs unsupervised learning

Tiêu chí	Học bán giám sát (Semi-supervised learning)	Học không giám sát (unsupervised learning)
Mục tiêu chung	Giảm thiểu sự phụ thuộc vào lượng lớn dữ liệu được dán nhãn	Giảm thiểu sự phụ thuộc vào lượng lớn dữ liệu được dán nhãn.
Dữ liệu sử dụng	Cần một lượng dữ liệu đã được dán nhãn kết hợp với dữ liệu chưa dán nhãn.	Hoàn toàn không giám sát (như autoencoders), không sử dụng dữ liệu dán nhãn.
Cơ sở thực tế	Yêu cầu "cơ sở thực tế" từ bên ngoài dưới hình thức dữ liệu đã được dán nhãn.	Tự trích xuất "cơ sở thực tế" từ chính cấu trúc tiềm ẩn của các mẫu dữ liệu chưa dán nhãn.
Tính ứng dụng của tác vụ	Huấn luyện mô hình trực tiếp để đưa ra dự đoán/phân loại.	Thường không hữu ích nếu đứng độc lập (gọi là "pretext tasks"). Mục đích chính là dạy mô hình cách biểu diễn dữ liệu để phục vụ cho các "tác vụ hạ nguồn" (downstream tasks) sau đó
Mối liên hệ	Là phương pháp tổng thể sử dụng cả dữ liệu có nhãn và không nhãn.	Khi kết hợp các tác vụ tự giám sát (pretext) với các tác vụ hạ nguồn có giám sát, nó sẽ trở thành một phần của quá trình học bán giám sát.

Bảng 2: So sánh giữa Học bán giám sát và Học không giám sát

CÁCH HỌC MÁY BÁN GIÁM SÁT HOẠT ĐỘNG

Học bán giám sát (SSL) dựa trên những giả định cụ thể về mối liên hệ giữa dữ liệu chưa dán nhãn và các phân lớp khác nhau. Điều quan trọng là dữ liệu chưa dán nhãn phải liên quan trực tiếp đến tác vụ mục tiêu của mô hình. Về mặt lý thuyết, phân phối của dữ liệu đầu vào phải cung cấp thông tin về xác suất một điểm dữ liệu thuộc về một lớp cụ thể. Ví dụ, một mô hình phân loại chó và mèo cần các hình ảnh chưa dán nhãn về chó và mèo, chứ không phải hình ảnh xe máy. Mặc dù việc bổ sung dữ liệu chưa dán nhãn phù hợp thường giúp nâng cao hiệu suất mô hình, nhưng nếu đưa vào dữ liệu không tương thích, hiệu suất thực tế có thể bị giảm sút so với việc hoàn toàn không sử dụng dữ liệu chưa dán nhãn. Mối quan hệ nền tảng này chính là cơ sở cho các giả định cốt lõi đằng sau hầu hết các thuật toán SSL.

Giả định cụm


Giả định cụm nêu rõ rằng các điểm dữ liệu thuộc cùng một cụm – một tập hợp các điểm dữ liệu giống nhau hơn so với các điểm dữ liệu có sẵn khác – cũng sẽ thuộc cùng một lớp.

Giả định độ mịn

Giả định này, còn được gọi là giả định về tính liên tục, phổ biến đối với hầu hết việc học có giám sát: ví dụ: các bộ phân loại học một phép tính gần đúng (hoặc “biểu diễn”) có ý nghĩa của từng lớp có liên quan trong quá trình đào tạo; Sau khi được đào tạo, chúng sẽ xác định cách phân loại các điểm dữ liệu mới thông qua cách biểu diễn mà chúng giống nhất.

Giả định mật độ thấp

Giả định mật độ thấp có thể được coi là phần mở rộng của giả định cụm (trong đó cụm điểm dữ liệu mật độ cao đại diện cho một lớp, thay vì ranh giới giữa các lớp) và giả định độ mịn (trong đó nếu nhiều điểm dữ liệu ở gần nhau, chúng sẽ chia sẻ một nhãn và do đó nằm về cùng một phía của ranh giới quyết định).



Hình 2: Độ mịn và giả định mật độ thấp

Giả định đa dạng

Giả định đa tập nói rằng không gian đầu vào có chiều cao hơn bao gồm nhiều đa tập chiều thấp hơn mà trên đó tất cả các điểm dữ liệu đều nằm và các điểm dữ liệu trên cùng một đa tập có cùng nhãn.

Giả định đa tập cho rằng khi một mô hình học hàm giảm kích thước phù hợp để loại bỏ thông tin không liên quan, các điểm dữ liệu khác nhau sẽ hội tụ thành một biểu diễn có ý nghĩa hơn mà các giả định SSL khác đáng tin cậy hơn.


Học chuyển đổi

Các phương pháp học chuyển đổi sử dụng các nhãn có sẵn để phân biệt các dự đoán nhãn cho một tập hợp các điểm dữ liệu chưa được gắn nhãn nhất định, để người học cơ sở được giám sát có thể sử dụng chúng.

Lan truyền nhãn

- Lan truyền nhãn (Label propagation) là một thuật toán dựa trên đồ thị, dùng để gán nhãn cho các điểm dữ liệu chưa dán nhãn dựa vào khoảng cách tương đối của chúng so với các điểm đã có nhãn.

- Thuật toán sử dụng một thước đo khoảng cách (như khoảng cách Euclid) để đánh giá.



Hình 3: Cơ chế lan truyền nhãn

Học quy nạp

Các phương pháp quy nạp của học bán giám sát nhằm mục đích đào tạo trực tiếp mô hình phân loại (hoặc hồi quy), sử dụng cả dữ liệu được dán nhãn và không được dán nhãn.

Phương pháp bao bọc

Trước tiên huấn luyện mô hình trên dữ liệu được gắn nhãn có sẵn—hoặc chỉ cần sử dụng trình phân loại phù hợp có sẵn—sau đó tạo dự đoán nhãn giả cho các điểm dữ liệu chưa được gắn nhãn. Sau đó, mô hình có thể được đào tạo lại bằng cách sử dụng cả dữ liệu được gắn nhãn ban đầu và dữ liệu được gắn nhãn giả, không phân biệt giữa hai dữ liệu.

Tự học

Tự đào tạo là một phương pháp bao bọc cơ bản. Nó yêu cầu các dự đoán nhãn giả mang tính xác suất, thay vì mang tính xác định: ví dụ: một mô hình tạo ra “85 phần trăm chó, 15 phần trăm mèo” thay vì chỉ xuất ra “chó”.

Đồng đào tạo

Một cách tiếp cận điển hình là sử dụng các thuật toán khác nhau cho mỗi bộ phân loại. Một cách khác là để mỗi bộ phân loại tập trung vào một tập hợp con dữ liệu khác nhau: ví dụ: trong dữ liệu video, đào tạo một người học cơ bản về dữ liệu hình ảnh và người kia về dữ liệu âm thanh.

RECOMMENDATION ENGINE

Collaborative filtering

Lọc cộng tác là một loại hệ thống gợi ý. Nó nhóm người dùng dựa trên hành vi tương tự, đề xuất các mặt hàng mới theo đặc điểm của nhóm.

Nói cách khác, thuật toán lọc cộng tác nhóm người dùng dựa trên hành vi và sử dụng các đặc điểm chung của nhóm để đề xuất các mặt hàng cho người dùng mục tiêu. Hệ thống gợi ý hợp tác hoạt động trên nguyên tắc những người dùng tương tự (về hành vi) có chung sở thích và thị hiếu giống nhau.

Có 2 kiểu lọc phổ biến:

Tiêu chí	Lọc cộng tác (Collaborative filtering)	Lọc dựa trên nội dung (Content-based filtering)
Cơ sở đề xuất	Dựa trên sự tương đồng giữa các người dùng (user similarity).	Dựa trên các đặc điểm/thuộc tính của bản thân vật phẩm (item profile features).
Cách tiếp cận	Phân nhóm người dùng có hành vi giống nhau để đưa ra gợi ý.	Đề xuất các vật phẩm tương tự với những vật phẩm mà người dùng đó đã tương tác tích cực trong quá khứ.
Đối tượng mục tiêu	Hướng các đề xuất đến một nhóm hoặc một tệp người dùng chung (group or type).	Hướng các đề xuất tập trung vào sở thích của một người dùng cụ thể (one specific user's preferences).

Bảng 3: So sánh thuật toán Lọc cộng tác và Lọc dựa trên nội dung

Cách hoạt động của lọc cộng tác

Lọc cộng tác sử dụng ma trận để ánh xạ hành vi của người dùng cho từng mục trong hệ thống của nó.

User-item matrix

User-item matrix (Ma trận người dùng - vật phẩm, hay còn gọi là ma trận đánh giá của người dùng) là một cấu trúc dữ liệu dùng trong lọc cộng tác để biểu diễn sở thích hoặc hành vi của từng cá nhân đối với từng vật phẩm trong hệ thống. Dưới đây là ví dụ về ma trận thời gian của người dùng cho một trang web hiệu sách:

	Dragon Ball	Naruto	One Piece	Doraemon
MCK	5	4	3	4
Wrxdie	1	2	4	5
Tlinh	1	2	3	<i>null</i>
Obito	<i>null</i>	4	3	1

Bảng 4: Ví dụ ma trận đánh giá của người dùng đối với các tác phẩm

Ma trận này hiển thị xếp hạng của người dùng cho các cuốn sách khác nhau hiện có. Thuật toán lọc cộng tác so sánh xếp hạng do người dùng cung cấp cho mỗi cuốn sách.

Cosine similarity

Cosine similarity (độ tương tự cosine) biểu thị số đo góc giữa hai vectơ. Các vectơ so sánh bao gồm một tập hợp con xếp hạng cho người dùng hoặc mục nhất định. Điểm tương tự cosine có thể là bất kỳ giá trị nào từ -1 đến 1. Điểm cosine càng cao thì hai mục càng được coi là giống nhau. Được biểu diễn bằng công thức dưới đây:

$$\text{Cosine}(x, y) = \frac{\sum_{i=1}^n x_i y_i}{\sqrt{\sum_{i=1}^n x_i^2} \sqrt{\sum_{i=1}^n y_i^2}} \quad (1)$$

Pearson correlation coefficient (PCC)

PCC giúp đo lường mức độ tương tự giữa các mục hoặc người dùng bằng cách tính toán mối tương quan giữa xếp hạng tương ứng của hai người dùng hoặc các mục. PCC nằm trong khoảng từ -1 đến 1, biểu thị mối tương quan âm với giống hệt nhau. Không giống như độ tương tự cosine, PCC sử dụng tất cả các xếp hạng cho một người dùng hoặc mục nhất định. Công thức tính PCC giữa 2 người dùng:

$$\text{PCC} = \frac{\sum (r_{ai} - \bar{r}_a)(r_{bi} - \bar{r}_b)}{\sqrt{\sum (r_{ai} - \bar{r}_a)^2} \sqrt{\sum (r_{bi} - \bar{r}_b)^2}} \quad (2)$$

Các loại hệ thống gợi ý hợp tác

Memory-based

Memory-based systems (hệ thống dựa trên bộ nhớ) có thể chia thành hai loại:

- **User-based filtering** (Lọc dựa trên người dùng) đề xuất các mặt hàng cho người dùng mục tiêu dựa trên sở thích của người dùng về hành vi. Thuật toán đề xuất so sánh hành vi trong quá khứ của người dùng mục tiêu với những người dùng khác. Cụ thể, hệ thống chỉ định cho mỗi người dùng một trọng số thể hiện sự tương đồng được nhận thấy của họ với người dùng mục tiêu—đây là những người dùng lân cận với người dùng mục tiêu

- **Item-based filtering** (Lọc dựa trên mục) đề xuất các mặt hàng mới cho người dùng mục tiêu dựa trên hành vi của người dùng đó đối với các mặt hàng tương tự. Tuy nhiên, lưu ý rằng khi so sánh các mục, hệ thống cộng tác không so sánh các tính năng của mục (như lọc dựa trên nội dung) mà thay vào đó là cách người dùng tương tác với các mục đó. Ví dụ: trong hệ thống đề xuất phim, thuật toán có thể xác định các phim tương tự dựa trên mối tương quan giữa tất cả xếp hạng của người dùng cho từng phim (điều chỉnh theo xếp hạng trung bình của mỗi người dùng). Sau đó, hệ thống sẽ đề xuất một bộ phim mới cho người dùng mục tiêu dựa trên xếp hạng tương quan.

Ưu và nhược điểm của lọc cộng tác

Đặc điểm

Chi tiết của hệ thống Lọc cộng tác (Collaborative filtering)

Ưu điểm

- Cung cấp các đề xuất mới lạ (novel recommendations) hiệu quả hơn so với hệ thống lọc dựa trên nội dung.
 - Đưa ra gợi ý bằng cách tổng hợp từ nhóm người dùng có chung sở thích.
 - Có khả năng giới thiệu các mặt hàng hoàn toàn mới (không có chung thuộc tính với các mặt hàng người dùng đã thích trước đó) nhưng vẫn phù hợp với kiểu sở thích của họ.
-

Nhược điểm

- **Vấn đề khởi động lạnh (Cold start problem):** Hệ thống không thể đánh giá sự tương đồng khi một người dùng mới hoặc vật phẩm mới gia nhập hệ thống do hoàn toàn không có lịch sử tương tác.
 - **Dữ liệu thưa thớt (Data sparsity):** Hệ thống thường thiếu dữ liệu sở thích của người dùng đối với phần lớn các vật phẩm, làm cho không gian đặc trưng bị trống. Dữ liệu càng thưa thớt, các mô hình dự đoán càng kém hiệu quả. (Thường được khắc phục bằng các phương pháp giảm chiều dữ liệu như phân tích ma trận - matrix factorization, hoặc yêu cầu người dùng tự cung cấp thông tin).
-

Bảng 5: Ưu và nhược điểm của hệ thống Lọc cộng tác

Content-based filtering

Content-based filtering (lọc dựa trên nội dung) là một trong hai loại hệ thống đề xuất chính. Nó đề xuất các mặt hàng cho người dùng theo tính năng của từng mặt hàng.

Cách hoạt động của lọc dựa trên nội dung

Hệ thống đề xuất dựa trên nội dung (CBRS) kết hợp các thuật toán học máy và kỹ thuật khoa học dữ liệu để đề xuất các mục mới và trả lời các truy vấn.

Các thành phần của lọc dựa trên nội dung

Trong CBRS, công cụ đề xuất về cơ bản so sánh hồ sơ người dùng và hồ sơ vật phẩm để dự đoán tương tác giữa vật phẩm và người dùng và đề xuất các vật phẩm phù hợp.

- **Hồ sơ mục** là sự thể hiện của một mục trong hệ thống. Nó bao gồm bộ tính năng của một mục, có thể là các đặc điểm có cấu trúc bên trong hoặc siêu dữ liệu mô tả.

- **Hồ sơ người dùng** thể hiện sở thích và hành vi của người dùng. Nó có thể bao gồm các phân trình bày về những mục mà người dùng trước đây đã thể hiện sự quan tâm


Biểu diễn mục

CBRS thường biểu diễn các mục và người dùng dưới dạng các phần nhúng trong không gian vectơ. Các mục được chuyển đổi thành vectơ bằng cách sử dụng mô tả siêu dữ liệu hoặc đặc tính bên trong làm đối tượng địa lý. Ví dụ: giả sử chúng tôi xây dựng hồ sơ mục để giới thiệu tiểu thuyết mới cho người dùng như một phần của cửa hàng sách trực tuyến. Sau đó, chúng tôi tạo hồ sơ cho từng cuốn tiểu thuyết bằng siêu dữ liệu đại diện, chẳng hạn như tác giả, thể loại, v.v. Giá trị của tiểu thuyết cho một danh mục nhất định có thể được biểu thị bằng các giá trị Boolean, trong đó 1 biểu thị sự hiện diện của tiểu thuyết trong danh mục đó và 0 biểu thị sự vắng mặt của nó.

	Children's Lit	Adventure	Bidungsroman
Little Women	1	0	1
Northanger Abbey	0	0	1
Peter Pan	1	1	0
Treasure Island	1	1	0

Bảng 6: Ví dụ ma trận đặc trưng vật phẩm (Item Profile Matrix)

Ở đây, mỗi thể loại là một chiều khác nhau trong không gian vectơ của chúng ta, với các giá trị trong một cuốn tiểu thuyết nhất định thể hiện vị trí của nó trong không gian vectơ đó. Ví dụ: Little Women nằm ở (1,0,1), Northanger Abbey ở (0,0,1), v.v. Chúng ta có thể hình dung không gian vectơ mẫu này như sau:



Hình 4: Biểu diễn không gian đặc trưng 3 chiều của các vật phẩm

Các phép đo độ tương đồng

Cosine similarity (Độ tương tự cosine) biểu thị số đo góc giữa hai vectơ. Nó có thể có bất kỳ giá trị nào từ -1 đến 1. Điểm cosin càng cao thì hai mục càng được coi là giống nhau

$$\text{Cosine}(x, y) = \frac{\sum_{i=1}^n x_i y_i}{\sqrt{\sum_{i=1}^n x_i^2} \sqrt{\sum_{i=1}^n y_i^2}} \quad (3)$$

Euclid distance (Khoảng cách Euclid) đo chiều dài của một đoạn đường giả định nối hai điểm vectơ. Điểm khoảng cách Euclide có thể thấp tới 0 và không có giới hạn trên. Khoảng cách Euclide của hai vectơ vật phẩm càng nhỏ thì chúng càng được coi là giống nhau. Khoảng cách Euclide được tính bằng công thức này, trong đó x và y đại diện cho hai vectơ mục:

$$d(x, y) = \sqrt{\sum_{i=1}^n (y_i - x_i)^2} \quad (4)$$

Ưu và nhược điểm của lọc dựa trên nội dung

Đặc điểm	Chi tiết của hệ thống Lọc dựa trên nội dung (Content-based filtering)
----------	---

Ưu điểm

- **Xử lý tốt vật phẩm mới:** Khắc phục được một phần vấn đề khởi động lạnh (cold-start problem) đối với các mặt hàng/nội dung mới bằng cách dựa vào các đặc tính nội tại hoặc siêu dữ liệu (metadata) thay vì cần lịch sử tương tác của người dùng.
 - **Tính minh bạch cao:** Hệ thống có thể giải thích rõ lý do tại sao một vật phẩm được đề xuất (ví dụ: cùng thể loại, chung diễn viên), giúp người dùng dễ dàng đưa ra quyết định hơn.
-

Nhược điểm

- **Hạn chế về đặc trưng (Feature limitation):** Đề xuất phụ thuộc hoàn toàn vào các đặc trưng được hệ thống gán cho vật phẩm. Nếu người dùng thích một chi tiết không có trong hồ sơ dữ liệu (như một motif cốt truyện cụ thể), hệ thống sẽ không thể đưa ra gợi ý chính xác.
 - **Chuyên biệt hóa quá mức (Overspecialization):** Chỉ giới hạn đề xuất ở những nội dung tương tự với sở thích trong quá khứ, thiếu khả năng khám phá và mang đến những gợi ý mới mẻ, bất ngờ (điều mà lọc cộng tác làm được).
-

Bảng 7: Ưu và nhược điểm của hệ thống Lọc dựa trên nội dung

Thực nghiệm cơ chế Lọc cộng tác trên tập dữ liệu MovieLens 100K

1. Mục đích thực nghiệm

Thực nghiệm này nhằm mục đích mô phỏng cơ chế hoạt động của thuật toán Lọc cộng tác (Collaborative Filtering) trên môi trường dữ liệu thực tế. Qua đó, kiểm chứng khả năng tính toán độ tương đồng giữa các người dùng bằng hệ số Pearson (PCC) và trực quan hóa thách thức về vấn đề "dữ liệu thưa thớt" (Data sparsity) đã được đề cập trong lý thuyết.

2. Phân tích tập dữ liệu và Tính thưa thớt (Data Sparsity)

Nghiên cứu sử dụng tập dữ liệu chuẩn MovieLens 100K, bao gồm 100.000 lượt đánh giá (từ 1 đến 5 sao) của 943 người dùng đối với 1.682 bộ phim.

Khi khởi tạo Ma trận người dùng - vật phẩm (User-item matrix), quá trình đo lường thực tế cho thấy tỷ lệ các ô trống (những bộ phim chưa được người dùng đánh giá) lên tới 93.7%. Con số này phản ánh chính xác khó khăn cốt lõi của bài toán lọc cộng tác: Mô hình dự đoán phải tìm cách nhận diện các quy luật hành vi tiềm ẩn chỉ từ 6.3% không gian đặc trưng có dữ liệu, nhằm nội suy và lấp đầy 93.7% khoảng trống còn lại.

3. Đánh giá độ tương đồng và Khai phá "Láng giềng"

Hệ thống áp dụng Hệ số tương quan Pearson (PCC) để tính toán khoảng cách và tìm ra nhóm "láng giềng" (neighbors) có sở thích tương đồng nhất với Người dùng mục tiêu (User ID: 1).

Bảng 8: Top 5 người dùng có mức độ tương đồng cao nhất với User 1

ID Láng giềng (Neighbor ID)	Hệ số tương đồng Pearson (PCC)
273	1.0
351	1.0
811	1.0
511	1.0
866	1.0

Nhận xét: Việc các láng giềng đạt điểm tương quan tuyệt đối (1.0) là một hệ quả trực tiếp từ đặc tính thưa thớt của ma trận. Do lượng tương tác của mỗi cá nhân quá ít, hai người dùng có thể chỉ tình cờ cùng xem và đánh giá giống hệt nhau ở 1 hoặc 2 bộ

phim. Hệ thống tính toán dựa trên số lượng mẫu siêu nhỏ này sẽ tạo ra đường thẳng tương quan khớp hoàn hảo, cho thấy thuật toán có thể gặp rủi ro thiếu chính xác (overfitting) nếu không kết hợp thêm các phương pháp giảm chiều dữ liệu.

4. Kết quả dự đoán và Khuyến nghị

Từ danh sách láng giềng trên, thuật toán tiến hành lọc ra những bộ phim mà User 1 chưa xem, sau đó tính toán điểm số dự đoán bằng phương pháp trung bình có trọng số (dựa trên mức độ tương đồng).

Bảng 9: Top 3 bộ phim được đề xuất cho Người dùng 1

Thứ hạng	ID Phim (Item ID)	Tên bộ phim	Điểm số dự đoán
1	1500	Santa with Muscles (1996)	5.0
2	1189	Prefontaine (1997)	5.0
3	1293	Star Kid (1997)	5.0

Kết luận thực nghiệm: Hệ thống đã hoàn thành trọn vẹn vòng đời của một công cụ đề xuất dựa trên bộ nhớ (Memory-based). Dù đối mặt với ma trận vô cùng thưa thớt, thuật toán vẫn thành công trong việc khai thác thông tin từ các người dùng lân cận, lấp đầy các khoảng trống dữ liệu và đưa ra những đề xuất cá nhân hóa có giá trị cao cho người dùng mục tiêu.