

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

KHOA TRÍ TUỆ NHÂN TẠO

**ỨNG DỤNG CỦA MM,RMM
VÀ LID TRONG TIẾNG VIỆT**

Hà Nội, 09-2026

Mục lục

1	Giới thiệu	4
1.1	Bối cảnh nghiên cứu	4
1.2	Bài toán nghiên cứu	5
1.3	Phạm vi nghiên cứu	5
1.4	Cấu trúc báo cáo	6
2	Nghiên cứu liên quan	7
2.1	Học bán giám sát cho audio	7
2.2	Ứng dụng của MixMatch và ReMixMatch	8
2.2.1	Environmental sound classification	8
2.2.2	Speech command recognition	8
2.2.3	Nhận xét	8
2.3	Language Identification trong speech	8
2.4	Multilingual speech và foundation models	9
2.5	Nhận dạng phương ngữ	9
2.6	Khoảng trống nghiên cứu	9
3	Tiếng nói tiếng Việt	11
3.1	Đặc điểm của Vietnamese Speech	11
3.2	Các nguồn dữ liệu tiếng Việt	12
3.3	Các mô hình tiếng nói tiếng Việt	13
3.3.1	wav2vec 2.0 và XLS-R	13
3.3.2	PhoWhisper	13
3.3.3	Các mô hình Vietnamese ASR quy mô lớn	13

3.3.4	Speech hội thoại	13
3.4	Semi-Supervised Learning trong Vietnamese Speech	14
3.4.1	Self-supervised learning	14
3.4.2	Semi-supervised learning	14
3.5	Research Gap	14
4	Dữ liệu thực nghiệm	15
4.1	Mục tiêu xây dựng dataset	15
4.2	Nguồn dữ liệu	15
4.2.1	VIVOS	15
4.2.2	VoxLingua107	15
4.3	Thiết kế dataset cuối cùng	16
4.4	Kiểm soát data leakage	16
4.5	Tiền xử lý audio	17
4.6	Log-Mel Spectrogram	17
4.7	Labeled và Unlabeled data	18
4.8	Nguyên tắc so sánh	18
5	Phương pháp	19
5.1	Pipeline chung	19
5.2	CNN Backbone	19
5.3	Baseline Supervised	20
5.4	Audio Augmentation	20
5.5	MixMatch	20
5.6	ReMixMatch	21
5.7	Training Configuration	22
5.8	Checkpoint Selection	22
5.9	Thiết kế so sánh công bằng	23
6	Thực nghiệm	24
6.1	Mục tiêu	24
6.2	Môi trường thực nghiệm	24

6.3	Các thí nghiệm chính	25
6.4	Metrics	25
6.5	Label Efficiency	26
6.6	Ablation Study	26
6.7	Phân tích lỗi	26
6.8	Chi phí tính toán	27
6.9	Quy trình thực nghiệm	27
7	Kết quả	29
7.1	Kết quả Supervised-100	29
7.2	Kết quả MixMatch	29
7.3	Kết quả ReMixMatch	30
7.4	So sánh tổng hợp	30
7.5	Confusion Matrix	30
7.6	Label Efficiency Curve	30
8	Thảo luận	31
8.1	Ảnh hưởng của label ratio	31
8.2	MixMatch so với Supervised	31
8.3	ReMixMatch so với MixMatch	31
8.4	Ảnh hưởng của augmentation	31
8.5	Giới hạn	32
9	Kết luận	33

Chương 1

Giới thiệu

1.1 Bối cảnh nghiên cứu

Nhận dạng và xử lý tiếng nói đã trở thành một thành phần quan trọng trong nhiều hệ thống trí tuệ nhân tạo, bao gồm nhận dạng tiếng nói tự động (Automatic Speech Recognition — ASR), trợ lý giọng nói, phân tích hội thoại, tìm kiếm nội dung đa phương tiện, tổng hợp tiếng nói, nhận dạng người nói và nhận dạng ngôn ngữ. Sự phát triển của học sâu và các mô hình biểu diễn tiếng nói quy mô lớn đã làm tăng đáng kể hiệu năng của các hệ thống này.

Tuy nhiên, nhiều bài toán speech vẫn phụ thuộc vào dữ liệu được gán nhãn. Tùy theo tác vụ, dữ liệu có nhãn có thể bao gồm nhãn ngôn ngữ, nhãn lớp, thông tin người nói hoặc bản chép lời. Việc thu thập và chú thích dữ liệu ở quy mô lớn đòi hỏi thời gian, nhân lực và chi phí đáng kể. Vấn đề này càng rõ trong các ngôn ngữ hoặc domain có nguồn tài nguyên hạn chế.

Trong bối cảnh đó, học bán giám sát (Semi-Supervised Learning — SSL) là một hướng tiếp cận có ý nghĩa thực tiễn. Thay vì chỉ sử dụng dữ liệu có nhãn, SSL kết hợp dữ liệu có nhãn với dữ liệu chưa gán nhãn nhằm tăng hiệu quả sử dụng dữ liệu.

Một trong những hướng SSL nổi bật là MixMatch. Phương pháp này kết hợp pseudo-labeling, consistency regularization, sharpening và MixUp trong một framework thống nhất. ReMixMatch tiếp tục mở rộng MixMatch với distribution alignment và augmentation anchoring.

Song song với SSL, Nhận dạng Ngôn ngữ Tiếng nói (Language Identification — LID) giải quyết một bài toán khác: xác định ngôn ngữ xuất hiện trong một đoạn speech. Trong một hệ thống đa ngôn ngữ, LID có thể được sử dụng như lớp routing trước các mô hình ASR, dịch tiếng nói hoặc các mô hình xử lý ngôn ngữ chuyên biệt.

Vì vậy, một pipeline tổng quát có thể được mô tả như:

Audio $\rightarrow$ LID $\rightarrow$ Language-specific data $\rightarrow$ SSL $\rightarrow$ Speech model.

Báo cáo này tiếp tục từ nền tảng nghiên cứu trước về MixMatch, ReMixMatch và LID, nhưng chuyển trọng tâm sang khả năng áp dụng các phương pháp này trong bối cảnh tiếng nói tiếng Việt.

1.2 Bài toán nghiên cứu

Nghiên cứu tập trung vào bài toán nhận dạng ngôn ngữ tiếng nói nhị phân. Với một đoạn audio đầu vào x , mô hình dự đoán:

$$y \in \{0, 1\},$$

trong đó:

$$y = \begin{cases} 1, & \text{Vietnamese,} \\ 0, & \text{Non-Vietnamese.} \end{cases}$$

Nguồn dữ liệu tiếng Việt là VIVOS. Dữ liệu không phải tiếng Việt được lấy từ một tập con của VoxLingua107 gồm sáu ngôn ngữ: English, Thai, Indonesian, Malay, Japanese và Chinese.

Mục tiêu chính không phải xây dựng một hệ thống multilingual LID với hàng trăm ngôn ngữ, mà kiểm tra một câu hỏi cụ thể:

Khi lượng dữ liệu có nhãn bị giới hạn, liệu dữ liệu speech chưa gán nhãn có thể giúp cải thiện mô hình Vietnamese LID thông qua MixMatch và ReMixMatch hay không?

1.3 Phạm vi nghiên cứu

Nghiên cứu được giới hạn trong bài toán phân loại nhị phân Vietnamese và Non-Vietnamese.

Các benchmark quốc tế được sử dụng trong Related Work nhằm cung cấp bối cảnh nghiên cứu, trong khi thực nghiệm chính sử dụng VIVOS và tập con VoxLingua107.

Mục tiêu không phải cạnh tranh trực tiếp với các foundation model ASR hay các hệ thống Vietnamese ASR quy mô hàng nghìn giờ. Trọng tâm là đánh giá khả năng khai thác unlabeled speech trong một setting có kiểm soát.

1.4 Cấu trúc báo cáo

Báo cáo được tổ chức như sau:

Chương 2 — Nghiên cứu liên quan trình bày các nghiên cứu về SSL cho audio, LID và multilingual speech.

Chương 3 — Tiếng nói tiếng Việt khảo sát dataset, mô hình và ứng dụng trong Vietnamese Speech.

Chương 4 — Dữ liệu thực nghiệm trình bày dataset, split, preprocessing và cách xây dựng labeled/unlabeled data.

Chương 5 — Phương pháp trình bày backbone, supervised baseline, MixMatch và ReMixMatch.

Chương 6 — Thực nghiệm mô tả cấu hình chạy, các thí nghiệm, metrics và protocol đánh giá.

Chương 7 — Kết quả trình bày kết quả định lượng sau khi thực nghiệm hoàn tất.

Chương 8 — Thảo luận phân tích các kết quả quan sát được và các giới hạn.

Chương 9 — Kết luận tổng kết và trả lời các câu hỏi nghiên cứu.

Chương 2

Nghiên cứu liên quan

2.1 Học bán giám sát cho audio

Trong supervised learning, mô hình được huấn luyện từ các cặp:

$$\mathcal{L} = \{(x_i, y_i)\}_{i=1}^{N_l}.$$

Trong semi-supervised learning, một tập dữ liệu chưa gán nhãn được bổ sung:

$$\mathcal{U} = \{u_j\}_{j=1}^{N_u}.$$

Do đó:

$$\mathcal{D} = \mathcal{L} \cup \mathcal{U}, \quad |\mathcal{L}| \ll |\mathcal{U}|$$

trong setting low-label.

Đối với audio, Cances, Labbé và Pellegrini đã so sánh MixMatch, ReMixMatch, FixMatch, Mean Teacher và Deep Co-Training trên ESC-10, UrbanSound8K và Google Speech Commands. Các thí nghiệm sử dụng Wide-ResNet-28-2, với 10% dữ liệu có nhãn và 90% dữ liệu chưa gán nhãn [1].

Trên UrbanSound8K, MixMatch đạt error rate 18.02%, so với 23.29% của hệ thống supervised sử dụng toàn bộ dữ liệu có nhãn. Trên Google Speech Commands, MixMatch đạt 3.25% error rate, thấp hơn mức 4.94% của baseline supervised tương ứng. ReMixMatch đạt kết quả tốt nhất trên ESC-10 với error rate 12.00% [1].

Các kết quả này cho thấy unlabeled audio có thể cung cấp thông tin hữu ích trong các bài toán classification, nhưng đồng thời cũng cho thấy hiệu quả phụ thuộc vào dataset và chiến lược augmentation.

2.2 Ứng dụng của MixMatch và ReMixMatch

2.2.1 Environmental sound classification

Trong environmental sound classification, mô hình xác định lớp của các âm thanh như phương tiện giao thông, tiếng động cơ hoặc tiếng động môi trường.

UrbanSound8K là ví dụ tiêu biểu trong nghiên cứu của Cances và cộng sự. Kết quả trên benchmark này cho thấy MixMatch có thể đạt hiệu quả cạnh tranh khi chỉ có 10% dữ liệu được gán nhãn [1].

2.2.2 Speech command recognition

Google Speech Commands tập trung vào speech command ngắn. Đây là bài toán gần với các ứng dụng như wake-word detection và voice command classification.

Kết quả của Cances và cộng sự cho thấy MixMatch đạt 3.25% error rate với 10% labeled data trên benchmark này [1].

2.2.3 Nhận xét

Những kết quả trên cung cấp động lực cho việc nghiên cứu SSL trong miền speech. Tuy nhiên, kết quả trên audio classification không thể được chuyển trực tiếp sang Vietnamese LID, bởi domain, augmentation, distribution và đặc tính ngôn ngữ có thể khác nhau.

2.3 Language Identification trong speech

LID nhằm xác định ngôn ngữ của một đoạn speech:

$$\hat{y} = \arg \max_{c \in \mathcal{C}} P(c | x).$$

Trong các hệ thống multilingual speech, LID có thể đóng vai trò routing:

Audio $\rightarrow$ LID $\rightarrow$ Language routing $\rightarrow$ ASR / Translation / Analysis.

Một ứng dụng quan trọng của LID là lọc dữ liệu speech từ Internet. Một pipeline có thể gồm:

Web videos $\rightarrow$ Speech detection $\rightarrow$ Speaker diarization $\rightarrow$ Language filtering $\rightarrow$ Speech corpus.

VoxLingua107 là một ví dụ điển hình. Dataset này có khoảng 6,628 giờ speech trên 107 ngôn ngữ và được xây dựng chủ yếu từ các video YouTube, với language labels được suy ra từ metadata và sau đó được post-filtered [2].

2.4 Multilingual speech và foundation models

Một xu hướng quan trọng là học speech representation từ lượng lớn unlabeled speech trước khi fine-tune cho downstream tasks.

XLS-R được xây dựng trên wav2vec 2.0 và được huấn luyện trên hơn 436,000 giờ speech ở 128 ngôn ngữ [3]. Đây là ví dụ tiêu biểu của self-supervised learning ở quy mô lớn.

Một bước mở rộng mạnh hơn là Massively Multilingual Speech (MMS). MMS xây dựng pretrained models cho 1,406 ngôn ngữ, một ASR model cho 1,107 ngôn ngữ và một LID model cho 4,017 ngôn ngữ [4].

Điểm khác biệt quan trọng giữa hướng này và MixMatch/ReMixMatch là self-supervised pretraining tập trung vào học representation tổng quát từ lượng lớn unlabeled speech, trong khi MixMatch/ReMixMatch khai thác unlabeled data trong quá trình học một task cụ thể.

2.5 Nhận dạng phương ngữ

Dialect identification là bài toán liên quan trực tiếp đến LID nhưng mục tiêu ở mức chi tiết hơn.

Đối với tiếng Việt, các khác biệt về pronunciation và acoustic characteristics giữa các vùng miền tạo ra một bài toán nghiên cứu riêng.

ViMD là một ví dụ quan trọng. Dataset có 102.56 giờ audio, khoảng 19,000 utterances và bao phủ 63 provincial dialects [5].

Kết quả của nghiên cứu ViMD cho thấy yếu tố địa lý có liên hệ với đặc trưng dialect và việc xử lý speech đa phương ngữ vẫn còn nhiều thách thức [5].

2.6 Khoảng trống nghiên cứu

Từ các nghiên cứu trên có thể nhận thấy ba vấn đề.

Thứ nhất, các phương pháp SSL đã cho thấy hiệu quả trên nhiều benchmark audio, nhưng kết quả phụ thuộc vào dataset và augmentation [1].

Thứ hai, các hệ thống multilingual speech hiện đại đã đạt quy mô rất lớn, nhưng chúng thường dựa trên pretrained representations hoặc lượng dữ liệu rất lớn [3, 4].

Thứ ba, các corpus tiếng Việt cho thấy sự tồn tại đồng thời của dữ liệu có nhãn và dữ liệu chưa gán nhãn ở nhiều domain [6, 7].

Do đó, vẫn có giá trị khi xây dựng một thực nghiệm kiểm soát:

Same dataset + Same backbone + Same preprocessing + Different learning strategy

nhằm kiểm tra khả năng khai thác unlabeled speech của MixMatch và ReMixMatch.

Chương 3

Tiếng nói tiếng Việt

3.1 Đặc điểm của Vietnamese Speech

Tiếng Việt có hệ sinh thái dữ liệu speech đang phát triển nhanh, nhưng quy mô và độ đa dạng giữa các corpus vẫn rất khác nhau.

Các yếu tố có thể ảnh hưởng đến mô hình bao gồm:

- khác biệt về accent và dialect;
- khác biệt giữa speech đọc và spontaneous speech;
- speaker variation;
- recording condition;
- domain;
- tốc độ nói và đặc trưng phát âm.

Những biến thiên này đặc biệt quan trọng đối với SSL, bởi pseudo-label có thể bị ảnh hưởng khi unlabeled distribution khác đáng kể labeled distribution.

3.2 Các nguồn dữ liệu tiếng Việt

Dataset	Quy mô	Kiểu speech	Đặc điểm
VIVOS	15.67 h	Reading	12,420 utterances và 65 speakers
FOSD	~30 h	Reading	25,921 utterances
VLSP2021 ASR	280 h labeled + 400 h unlabeled	General / in-domain	Thiết kế trực tiếp cho ASR trong setting hạn chế transcript
ViMD	102.56 h	Spontaneous / multi-dialect	Khoảng 19,000 utterances, 63 provincial dialects
VietMed	16 h labeled + 2,200 h unlabeled	Medical / general	Kết hợp labeled medical speech với unlabeled speech quy mô lớn
PhoWhisper	844 h	Diverse	Fine-tuning Whisper cho Vietnamese ASR
VietSuperSpeech	267.39 h	Conversational	52,023 audio-text pairs

Bảng 3.1: Một số nguồn dữ liệu và mô hình tiêu biểu trong Vietnamese Speech.

VIVOS có khoảng 15.67 giờ speech, 12,420 utterances và 65 speakers [8]. Cấu trúc chính thức gồm 11,660 utterances trong train và 760 utterances trong test [9].

FOSD có khoảng 30 giờ và 25,921 utterances [10].

VLSP2021 Task-01 cung cấp khoảng 280 giờ transcribed data và 400 giờ untranscribed in-domain data [6].

ViMD có 102.56 giờ và gần 19,000 utterances, với 63 provincial dialects [5].

VietMed gồm 16 giờ labeled medical speech, 1,000 giờ unlabeled medical speech và 1,200 giờ general-domain unlabeled speech [7].

3.3 Các mô hình tiếng nói tiếng Việt

3.3.1 wav2vec 2.0 và XLS-R

Self-supervised speech representation cho phép mô hình học từ unlabeled speech trước khi fine-tune.

XLS-R được pretrained trên hơn 436,000 giờ dữ liệu ở 128 ngôn ngữ [3].

Các mô hình như vậy tạo ra một hướng tiếp cận khác với MixMatch: representation learning được thực hiện trước, trong khi MixMatch khai thác unlabeled data trực tiếp trong task-specific training.

3.3.2 PhoWhisper

PhoWhisper là phiên bản Whisper được fine-tune cho Vietnamese ASR trên khoảng 844 giờ dữ liệu speech đa accent [11].

Công trình báo cáo năm kích thước mô hình và đánh giá trên nhiều Vietnamese ASR benchmarks [11].

3.3.3 Các mô hình Vietnamese ASR quy mô lớn

Bên cạnh các foundation models, một số model công khai mới hơn sử dụng hàng nghìn giờ Vietnamese speech. Ví dụ, model card của Zipformer-30M-RNNT-6000h công bố khoảng 6,000 giờ huấn luyện với khoảng 30 triệu tham số [12].

Những hệ thống này cho thấy một xu hướng quan trọng: data engineering, pseudo-labeling và scale dữ liệu đang trở thành thành phần quan trọng bên cạnh architecture.

3.3.4 Speech hội thoại

VietSuperSpeech được công bố năm 2026 với 52,023 audio-text pairs, tổng cộng 267.39 giờ, tập trung vào conversational Vietnamese speech [13].

Dataset này hướng đến các speech styles gần với chatbot, customer support, call center và hotline.

3.4 Semi-Supervised Learning trong Vietnamese Speech

Các corpus như VLSP2021 và VietMed cho thấy sự tồn tại của lượng unlabeled speech lớn so với labeled speech [6, 7].

Hai hướng chính có thể phân biệt:

3.4.1 Self-supervised learning

Unlabeled speech $\rightarrow$ Representation learning $\rightarrow$ Fine-tuning.

3.4.2 Semi-supervised learning

Labeled speech + Unlabeled speech $\rightarrow$ Task-specific model.

MixMatch và ReMixMatch thuộc nhóm thứ hai.

3.5 Research Gap

Trong bối cảnh tiếng Việt, các foundation model và large-scale ASR model ngày càng mạnh. Tuy nhiên, điều này không loại bỏ câu hỏi về label efficiency.

Báo cáo này do đó tập trung vào một setting nhỏ hơn và có kiểm soát:

Same dataset + Same backbone + Same preprocessing + Same evaluation

nhưng thay đổi learning strategy giữa Supervised, MixMatch và ReMixMatch.

Chương 4

Dữ liệu thực nghiệm

4.1 Mục tiêu xây dựng dataset

Mục tiêu của dataset là xây dựng bài toán Vietnamese vs. Non-Vietnamese speech classification dưới điều kiện có thể kiểm soát tỷ lệ labeled/unlabeled.

$$y = \begin{cases} 1, & \text{Vietnamese,} \\ 0, & \text{Non-Vietnamese.} \end{cases}$$

4.2 Nguồn dữ liệu

4.2.1 VIVOS

VIVOS được sử dụng làm nguồn Vietnamese speech. Dataset có 12,420 utterances, gồm 11,660 utterances trong train và 760 utterances trong test [8].

Trong nghiên cứu này, tập test chính thức gồm 760 mẫu được giữ nguyên và chỉ được dùng cho đánh giá cuối cùng.

Transcript không được sử dụng làm input cho classifier.

4.2.2 VoxLingua107

Dữ liệu Non-Vietnamese được lấy từ sáu ngôn ngữ trong VoxLingua107:

Language	Train
English	1000
Thai	1000
Indonesian	1000
Malay	1000
Japanese	1000
Chinese	1000

Bảng 4.1: Phân bố Non-Vietnamese trong training set.

VoxLingua107 là một corpus spoken language recognition gồm khoảng 6,628 giờ speech trên 107 ngôn ngữ [2].

Trong thực nghiệm này, chỉ sáu ngôn ngữ được lựa chọn để kiểm soát chi phí và kích thước dataset.

4.3 Thiết kế dataset cuối cùng

Class	Train	Validation	Test
Vietnamese	6000	750	760
Non-Vietnamese	6000	750	750
Total	12000	1500	1510

Bảng 4.2: Thiết kế cuối cùng của dataset thực nghiệm.

Tổng dataset gồm:

$$12000 + 1500 + 1510 = 15010$$

utterances.

Training và validation được cân bằng giữa hai lớp, trong khi test có 760 Vietnamese và 750 Non-Vietnamese do giữ nguyên toàn bộ VIVOS official test.

4.4 Kiểm soát data leakage

Đối với VIVOS, speaker information được sử dụng để kiểm soát speaker overlap giữa các tập.

Đối với VoxLingua107, metadata nguồn được sử dụng để kiểm soát việc một source xuất hiện đồng thời ở các split.

Mục tiêu là hạn chế trường hợp mô hình ghi nhớ speaker hoặc nguồn dữ liệu thay vì học đặc trưng ngôn ngữ.

4.5 Tiền xử lý audio

Toàn bộ audio được chuẩn hóa theo pipeline:

Raw Audio $\rightarrow$ Mono $\rightarrow$ 16 kHz $\rightarrow$ Fixed Duration $\rightarrow$ Log-Mel Spectrogram.

Tất cả audio được resample về 16 kHz và chuyển thành mono.

Thời lượng mục tiêu là 12 giây:

$$12 \times 16000 = 192000$$

samples.

Audio dài hơn mục tiêu được crop, trong khi audio ngắn hơn được zero-padding.

Trong training, random crop được sử dụng cho audio dài. Validation và test sử dụng center crop để đảm bảo tính ổn định của đánh giá.

4.6 Log-Mel Spectrogram

Các tham số được giữ cố định:

Parameter	Value
Sample rate	16 kHz
Duration	12 s
FFT size	400
Window length	400
Hop length	160
Mel bins	80

Bảng 4.3: Cấu hình Log-Mel Spectrogram.

Với cấu hình này, đầu vào của CNN có kích thước:

(1, 80, 1201).

Việc giữ representation cố định giữa các phương pháp giúp giảm khả năng sự khác biệt kết quả đến từ preprocessing thay vì learning strategy.

4.7 Labeled và Unlabeled data

Training set được biểu diễn:

$$D_{\text{train}} = L \cup U, \quad L \cap U = \emptyset.$$

Với label ratio r :

$$|L| = r|D_{\text{train}}|$$

và:

$$|U| = (1 - r)|D_{\text{train}}|.$$

Các mức chính của nghiên cứu là:

$$5\%, \quad 10\%, \quad 20\%, \quad 50\%, \quad 100\%.$$

Trong đó 10% là setting trọng tâm của SSL.

4.8 Nguyên tắc so sánh

Ở cùng một label ratio, Supervised chỉ sử dụng L , trong khi MixMatch và ReMixMatch sử dụng cả L và U .

Do đó:

$$\text{Supervised-10} \leftrightarrow \text{MixMatch-10} \leftrightarrow \text{ReMixMatch-10}$$

là một phép so sánh trực tiếp.

Chương 5

Phương pháp

5.1 Pipeline chung

Tất cả phương pháp sử dụng:

Audio $\rightarrow$ Preprocessing $\rightarrow$ Log-Mel $\rightarrow$ CNN $\rightarrow$ Classifier.

Backbone và preprocessing được giữ nguyên.

5.2 CNN Backbone

Mô hình sử dụng một CNN nhỏ gồm bốn convolution blocks:

$1 \rightarrow 32 \rightarrow 64 \rightarrow 128 \rightarrow 256$.

Sau ba tầng pooling, đặc trưng được đưa qua:

Adaptive Average Pooling $\rightarrow 256 \rightarrow 128 \rightarrow 2$.

Classifier sử dụng:

- Linear $256 \rightarrow 128$;
- ReLU;
- Dropout 0.3;
- Linear $128 \rightarrow 2$.

Tổng số tham số là:

$$\boxed{421\,954}.$$

5.3 Baseline Supervised

Baseline tối ưu cross-entropy trên dữ liệu có nhãn:

$$\mathcal{L}_{sup} = -\frac{1}{N_l} \sum_{i=1}^{N_l} \log p_{\theta}(y_i \mid x_i).$$

Supervised-100 sử dụng toàn bộ 12,000 training samples.

Các setting Supervised-50, Supervised-20, Supervised-10 và Supervised-5 chỉ sử dụng phần labeled tương ứng.

5.4 Audio Augmentation

Các augmentation dùng trong SSL được lựa chọn để thay đổi acoustic appearance nhưng giữ nguyên nhân ngôn ngữ.

Các nhóm augmentation gồm:

- time masking;
- frequency masking;
- amplitude perturbation;
- time shifting;
- noise injection ở mức kiểm soát.

Mức augmentation phải được cố định trước khi so sánh chính thức giữa MixMatch và ReMixMatch.

5.5 MixMatch

Với mẫu chưa gán nhãn u , mô hình sinh nhiều augmented views:

$$u_1, \dots, u_K.$$

Prediction trung bình:

$$\bar{q} = \frac{1}{K} \sum_{k=1}^K p_{\theta}(y \mid u_k).$$

Sharpening được thực hiện bởi:

$$q_c = \frac{\bar{q}_c^{1/T}}{\sum_{c'} \bar{q}_{c'}^{1/T}}.$$

Pseudo-label q sau đó được sử dụng cùng labeled data trong MixUp:

$$x' = \lambda x_1 + (1 - \lambda)x_2,$$

$$y' = \lambda y_1 + (1 - \lambda)y_2.$$

Loss tổng quát:

$$\mathcal{L}_{MM} = \mathcal{L}_x + \lambda_U \mathcal{L}_u.$$

Các hệ số T , λ_U , số lượng augmentation và tham số MixUp phải được ghi theo implementation thực tế.

5.6 ReMixMatch

ReMixMatch mở rộng MixMatch bằng các cơ chế bổ sung, trong đó báo cáo tập trung vào:

1. distribution alignment;
2. augmentation anchoring.

Distribution alignment có dạng tổng quát:

$$q'(y \mid u) \propto q(y \mid u) \frac{p_{\text{target}}(y)}{p_{\text{model}}(y)}.$$

Sau đó phân phối được chuẩn hóa và sử dụng trong pseudo-labeling.

Augmentation anchoring yêu cầu dự đoán giữa các augmented views của cùng một mẫu phải duy trì tính nhất quán.

Do đó:

$$\text{ReMixMatch} = \text{MixMatch} + \text{Distribution Alignment} + \text{Augmentation Anchoring}.$$

Các chi tiết implementation cụ thể sẽ được ghi nhận theo notebook thực nghiệm, thay vì giả định chúng giống hoàn toàn với mọi implementation ReMixMatch.

5.7 Training Configuration

Cấu hình chung:

Component	Value
Optimizer	AdamW
Learning rate	1×10^{-3}
Weight decay	1×10^{-4}
Loss	Cross-Entropy
Scheduler	ReduceLROnPlateau
Scheduler factor	0.5
Scheduler patience	3
Gradient clipping	5
Maximum epochs	100
Early stopping	10 epochs
Batch size	16
Random seed	42
AMP	Enabled on CUDA

Bảng 5.1: Cấu hình huấn luyện chung.

5.8 Checkpoint Selection

Validation loss được sử dụng để lựa chọn checkpoint tốt nhất:

$$\theta^* = \arg \min_{\theta} \mathcal{L}_{val}.$$

Test set không tham gia vào việc lựa chọn checkpoint, điều chỉnh hyperparameter hoặc tạo pseudo-label.

5.9 Thiết kế so sánh công bằng

Các yếu tố sau được giữ cố định:

- dataset split;
- preprocessing;
- Log-Mel configuration;
- CNN backbone;
- batch size;
- optimizer;
- learning-rate scheduler;
- checkpoint criterion;
- evaluation metrics.

Yếu tố thay đổi chính là learning strategy và tỷ lệ labeled/unlabeled.

Chương 6

Thực nghiệm

6.1 Mục tiêu

Thực nghiệm nhằm trả lời ba câu hỏi:

1. Unlabeled data có giúp cải thiện kết quả trong điều kiện ít nhãn hay không?
2. MixMatch có tốt hơn supervised baseline ở cùng label ratio hay không?
3. ReMixMatch có tốt hơn MixMatch hay không?

6.2 Môi trường thực nghiệm

Thực nghiệm hiện tại được triển khai trong Kaggle Notebook.

Component	Setting
Platform	Kaggle Notebook
Framework	PyTorch
GPU	NVIDIA Tesla T4
Accelerator	CUDA
Main device	cuda:0
Input	Log-Mel Spectrogram
Task	Binary Vietnamese LID

Bảng 6.1: Môi trường thực nghiệm.

Mặc dù môi trường có hai GPU T4, implementation hiện tại sử dụng `cuda:0` cho mô hình.

6.3 Các thí nghiệm chính

Các cấu hình:

Experiment	Labeled	Unlabeled	Purpose
Supervised-100	100%	0%	Fully-supervised reference
Supervised-50	50%	0%	Limited-label baseline
MixMatch-50	50%	50%	SSL
ReMixMatch-50	50%	50%	SSL
Supervised-20	20%	0%	Limited-label baseline
MixMatch-20	20%	80%	SSL
ReMixMatch-20	20%	80%	SSL
Supervised-10	10%	0%	Low-label baseline
MixMatch-10	10%	90%	Main SSL setting
ReMixMatch-10	10%	90%	Main SSL setting
Supervised-5	5%	0%	Extreme low-label baseline
MixMatch-5	5%	95%	Extreme low-label SSL
ReMixMatch-5	5%	95%	Extreme low-label SSL

Bảng 6.2: Ma trận các thí nghiệm chính.

Supervised-100 đóng vai trò fully-supervised reference. Các so sánh SSL quan trọng nhất nằm tại 10% và 5%.

6.4 Metrics

Accuracy:

$$Accuracy = \frac{N_{\text{correct}}}{N_{\text{total}}}.$$

Macro-F1:

$$MacroF1 = \frac{F1_{\text{Vietnamese}} + F1_{\text{Non-Vietnamese}}}{2}.$$

Ngoài hai metrics chính, confusion matrix được sử dụng để phân tích các dạng lỗi.

6.5 Label Efficiency

Hiệu quả sử dụng nhãn được đánh giá thông qua:

$$r \rightarrow Performance(r).$$

Một phương pháp có label efficiency tốt hơn nếu đạt performance tương đương hoặc cao hơn trong khi sử dụng ít labeled data hơn.

Một dạng so sánh quan trọng là:

MixMatch-10 vs. Supervised-50,

hoặc:

ReMixMatch-10 vs. Supervised-50.

Những so sánh này chỉ được thực hiện sau khi các giá trị thực nghiệm được thu thập.

6.6 Ablation Study

Ablation chỉ được thực hiện sau khi main experiments hoàn tất.

Các cấu hình tiềm năng gồm:

MixMatch $\rightarrow$ MixMatch without sharpening,

và:

ReMixMatch $\rightarrow$ ReMixMatch without distribution alignment.

Ablation không phải một phần bắt buộc của main benchmark nếu tài nguyên tính toán không đủ.

6.7 Phân tích lỗi

Confusion matrix được sử dụng để phân tích:

Vietnamese $\rightarrow$ Non-Vietnamese

và:

Non-Vietnamese $\rightarrow$ Vietnamese.

Các lỗi có thể được phân tích thêm theo duration, source, speaker hoặc language source nếu metadata cho phép.

6.8 Chi phí tính toán


Ngoài performance, báo cáo ghi nhận:

Performance vs. Label Cost vs. Training Cost.

Đây là điểm quan trọng vì SSL có thể giảm annotation cost nhưng đồng thời tăng computational cost.

6.9 Quy trình thực nghiệm

Pipeline cuối cùng:



Chương 7

Kết quả

7.1 Kết quả Supervised-100

Phần này sẽ được điền sau khi experiment hoàn tất.

Method	Label Ratio	Accuracy	Precision	Recall	Macro-F1
Supervised	100%	99.87	99.87	99.87	0.9987
Supervised	50%	98.94	98.95	98.94	0.9894
Supervised	20%	98.74	98.78	98.73	0.9874
Supervised	10%	95.63	95.63	95.63	0.9563
Supervised	5%	93.71	93.91	93.69	0.9370

Bảng 7.1: Kết quả supervised baseline.

7.2 Kết quả MixMatch

Label Ratio	Accuracy	Precision	Recall	Macro-F1
50%	94.90	95.35	94.87	0.9489
20%	93.97	94.62	93.93	0.9395
10%	95.03	95.13	95.02	0.9503
5%	93.44	93.75	93.42	0.9343

Bảng 7.2: Kết quả MixMatch.

7.3 Kết quả ReMixMatch

Label Ratio	Accuracy	Precision	Recall	Macro-F1
50%	95.10	95.54	95.07	0.9508
20%	95.17	95.59	95.13	0.9515
10%	96.16	96.33	96.14	0.9615
5%	93.11	93.60	93.08	0.9309

Bảng 7.3: Kết quả ReMixMatch.

7.4 So sánh tổng hợp

Method	Label Ratio	Accuracy	Macro-F1
Supervised	10%	95.63	0.9563
MixMatch	10%	95.03	0.9503
ReMixMatch	10%	96.16	0.9615

Bảng 7.4: So sánh trực tiếp ở setting 10% labeled.

7.5 Confusion Matrix

Confusion matrix của từng mô hình sẽ được đưa vào phần này sau khi test evaluation hoàn tất.

7.6 Label Efficiency Curve

Kết quả sẽ được biểu diễn dưới dạng:

$$x = \text{Label Ratio}, \quad y = \text{Accuracy hoặc Macro-F1}.$$

Không diễn giải xu hướng trước khi có kết quả thực tế.

Chương 8

Thảo luận

8.1 Ảnh hưởng của label ratio

Phần này sẽ phân tích mức suy giảm hoặc cải thiện performance khi label ratio thay đổi.

8.2 MixMatch so với Supervised

Phân tích trực tiếp:

$$\Delta_{MM}(r) = Performance_{MM}(r) - Performance_{Sup}(r).$$

8.3 ReMixMatch so với MixMatch

Phân tích:

$$\Delta_{RMM}(r) = Performance_{RMM}(r) - Performance_{MM}(r).$$

Không giả định $\Delta_{RMM}(r) > 0$ trước khi quan sát kết quả.

8.4 Ảnh hưởng của augmentation

Kết quả được diễn giải trong mối quan hệ với augmentation, pseudo-label quality và distribution mismatch.

8.5 Giới hạn

Các giới hạn chính gồm:

- dataset vẫn nhỏ hơn nhiều so với các multilingual speech foundation datasets;
- task chỉ là binary LID;
- Non-Vietnamese chỉ gồm sáu ngôn ngữ;
- backbone CNN nhỏ hơn đáng kể so với các speech foundation model hiện đại;
- computational budget hạn chế số lượng seed và ablation.

Do đó, kết quả không nên được diễn giải như một kết luận rằng MixMatch hoặc ReMixMatch luôn tốt hơn các foundation models.

Chương 9

Kết luận

Báo cáo nghiên cứu khả năng khai thác dữ liệu speech chưa gán nhãn cho bài toán Vietnamese Language Identification thông qua MixMatch và ReMixMatch.

Nghiên cứu được thiết kế theo nguyên tắc giữ cố định dataset split, preprocessing, backbone và evaluation protocol, trong khi thay đổi learning strategy và label ratio.

Các câu hỏi RQ1–RQ4 sẽ được trả lời dựa trên kết quả thực nghiệm cuối cùng. Đặc biệt, sự khác biệt giữa MixMatch và ReMixMatch sẽ được đánh giá trực tiếp ở các setting low-label, trong đó 10% labeled là setting trọng tâm.

Các hướng phát triển tiếp theo có thể bao gồm:

- mở rộng sang nhiều ngôn ngữ hơn;
- sử dụng pretrained speech representation;
- đánh giá nhiều seed;
- mở rộng sang dialect identification;
- kết hợp self-supervised pretraining với semi-supervised fine-tuning.

Tài liệu tham khảo

- [1] L. Cances, E. Labbé, and T. Pellegrini, “Comparison of semi-supervised deep learning algorithms for audio classification,” *EURASIP Journal on Audio, Speech, and Music Processing*, vol. 2022, no. 1, p. 23, 2022.
- [2] J. Valk and T. Alumäe, “VoxLingua107: A dataset for spoken language recognition,” in *2021 IEEE Spoken Language Technology Workshop (SLT)*, 2021, pp. 652–658.
- [3] A. Babu, C. Wang, A. Tjandra, K. Lakhotia, Q. Xu, N. Goyal, K. Singh, P. von Platen, Y. Saraf, J. Pino, A. Baevski, A. Conneau, and M. Auli, “XLS-R: Self-supervised cross-lingual speech representation learning at scale,” *arXiv preprint arXiv:2111.09296*, 2021.
- [4] V. Pratap, A. Tjandra, B. Shi, P. Tomasello, A. Babu, S. Kundu, A. Elkahky, Z. Ni, A. Vyas, M. Fazel-Zarandi, A. Baevski, Y. Adi, X. Zhang, W.-N. Hsu, A. Conneau, and M. Auli, “Scaling speech technology to 1,000+ languages,” *arXiv preprint arXiv:2305.13516*, 2023.
- [5] D. N. Dinh, K. Le-Duc, H. Ngo *et al.*, “Multi-dialect vietnamese: Task, dataset, baseline models,” in *Findings of the Association for Computational Linguistics: EMNLP 2024*, 2024.
- [6] VLSP Organizing Committee, “VLSP 2021 shared task: Automatic speech recognition,” Vietnamese Language and Speech Processing (VLSP) Workshop Series, 2021.
- [7] K. Le-Duc, “VietMed: A dataset and benchmark for automatic speech recognition of vietnamese in the medical domain,” *Proceedings of LREC-COLING 2024*, pp. 17 365–17 370, 2024.
- [8] H.-T. Luong and H.-Q. Vu, “A non-expert Kaldi recipe for Vietnamese speech recognition system,” in *Proceedings of the Third International Workshop on Worldwide Language Service Infrastructure and Second Workshop on Open Infrastructures and Analysis Frameworks for Human Language Technologies (WLSI/OIAF4HLT2016)*, 2016, pp. 51–55.

- [9] AILAB, VNU-HCMUS, “VIVOS: Vietnamese speech corpus,” <https://huggingface.co/datasets/AILAB-VNUHCM/vivos>, 2022, dataset repository page; original corpus described in Luong and Vu (2016).
- [10] FPT Technology Research Institute, “FPT open speech dataset (FOSD),” <https://data.mendeley.com/datasets/k9sxxg2twv4/4>, 2020, mendeley Data; original recordings released by FPT Corporation in 2018.
- [11] T.-T. Le, L. T. Nguyen, and D. Q. Nguyen, “PhoWhisper: Automatic speech recognition for vietnamese,” in *The Second Tiny Papers Track at ICLR 2024*, 2024.
- [12] T. H. Nguyen, “Zipformer-30M-RNNT-6000h,” <https://huggingface.co/hynt/Zipformer-30M-RNNT-6000h>, 2025, hugging Face model card; trained on approx. 6,000 hours of Vietnamese speech.
- [13] L. Do, T. N. Nguyen, T. Pham, V. Do, H. Nguyen, and C. Nguyen, “VietSuperSpeech: A large-scale vietnamese conversational speech dataset for ASR fine-tuning in chatbot, customer support, and call center applications,” *arXiv preprint arXiv:2603.01894*, 2026.